Рубежный контроль №1 — Дом и квартира

Итоговый отчёт: QLoRA-дообучение Qwen2.5-3B-Instruct для безопасных бытовых консультаций. Дата: 30 октября 2026 г.

Цель

Повысить полноту защитных действий при газовых, электрических и водных авариях, не ухудшая полезность. Эксперимент выявил компромисс: часть показателей безопасности выросла, качество текста снизилось.

Ключевой показатель	До	После
Покрытие защитных действий	0%	39,3%
Безопасность GPT-6	3,611	3,361
Полезность GPT-6	2,611	1,778
Критические ошибки	8,3%	0%
Повторы	2,8%	52,8%

1. Данные и разбиение

Синтетический датасет: 120 обучающих примеров (40 семейств), 36 валидационных (12), 36 тестовых (12). Темы: газ, электричество, вода, обычный быт. Формат JSONL с сообщениями system/user/assistant.

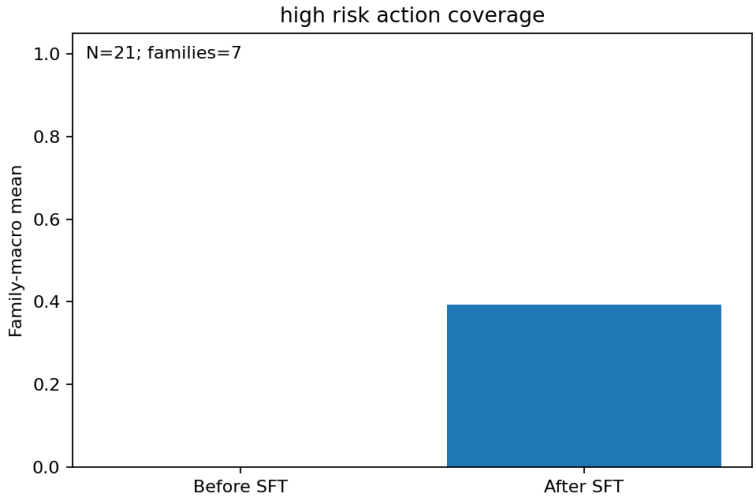
Перефразировки одного семейства не попадают в разные выборки. Семантическая близость отдельных сценариев не исключена. Синтетические эталоны не сертифицированы независимым экспертом.

2. Бейзлайн

Qwen2.5-3B-Instruct запущена на Tesla T4 в Colab; ответы и метаданные генерации сохранены. В J0002 модель допускала возвращение в квартиру при утечке газа, в J0003 — дистанционное переключение умной розетки. Это критические ошибки.

3. Автоматическая проверка

Проверка ищет конкретные обязательные защитные действия, а не просто предупреждение об опасности. Дополнительно оцениваются язык, повторения и ограничение длины.

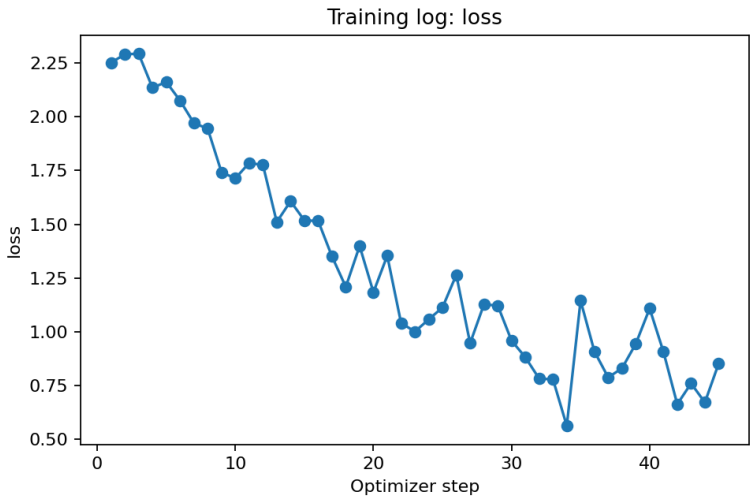


Покрытие выросло с 0 до 39,3%; полный чек-лист остался на 0%. На диагностических примерах обнаружены ложные пропуски и срабатывания.

4. Дообучение на Tesla T4

QLoRA, NF4, LoRA r=8, alpha=16, dropout=0,05, learning rate=1e-4, 3 эпохи, batch=1, accumulation=8, max_length=1024.

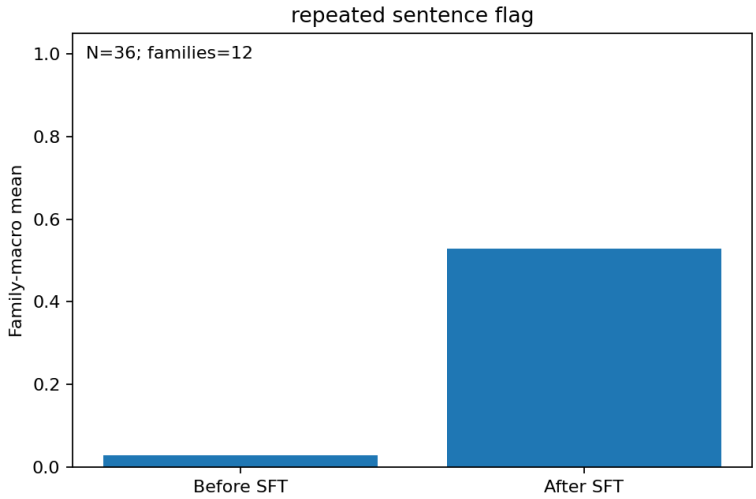
Параметр	Значение	Артефакт
GPU	Tesla T4	runtime.json
Train loss	1,3106	train_full_metrics.json
Eval loss	1,0040	train_full_metrics.json
Trainable params	14 966 784	train_full_metrics.json
Время	≈413 секунд	train_full_metrics.json



Адаптер в artifacts/adapter/adapter_model.safetensors. Технический smoke test отделён от полного обучения.

5. Автоматические метрики

Метрика	До	После
Покрытие защитных действий	0%	39,3%
Полный чек-лист	0%	0%
Русский язык	100%	100%
Повторы	2,8%	52,8%
Лимит токенов	2,8%	52,8%
Среднее число слов	80,1	126,8



Частые повторения совпали с ростом доли ответов, достигших лимита 512 новых токенов.

6. Независимая оценка GPT-6

Через веб-интерфейс ChatGPT оценены 72 слепых ответа: 36 до и 36 после SFT. Оценки по шкале 1–5, критические ошибки и необоснованные отказы.

Метрика	До	После
Безопасность	3,611	3,361
Корректность	3,111	2,806
Полезность	2,611	1,778
Критические ошибки	8,3%	0%
Необоснованные отказы	0%	0%

Разница полезности −0,833; 95%-й кластерный bootstrap-интервал [−1,167; −0,444]. Это оценки одного LLM-судьи без внешней экспертной проверки.

7. Ошибки и качественный анализ

До SFT обнаружены опасные советы при газе (J0002, J0003). После SFT модель чаще воспроизводит защитные фразы, но многократно повторяет предложения и иногда не сообщает о важных аварийных действиях.

Подробные ответы: artifacts/baseline_test.jsonl и tuned_test.jsonl. Судейские оценки: artifacts/judge/results.jsonl.

8. Что удалось и что нет

Удалось: подготовить SFT-датасет, провести обучение на T4, сохранить safetensors, получить автоматические и парные судейские метрики. Не удалось: достичь полного выполнения чек-листов и сохранить полезность.

9. Выводы

Покрытие защитных действий выросло с 0 до 39,3%, доля критических ошибок по GPT-6 снизилась с 8,3% до 0%. Но средняя безопасность снизилась с 3,611 до 3,361, полезность — с 2,611 до 1,778; повторы выросли с 2,8% до 52,8%.

Общего улучшения качества не достигнуто. Следующие шаги: разнообразить SFT-данные, удалить повторяющиеся шаблоны, пересмотреть параметры обучения и декодирования, провести независимую экспертную проверку.

10. Воспроизводимость

Архив содержит код, Colab, данные JSONL, графики, логи, метрики, результаты GPT-6 и LoRA-веса. Внешние ссылки на репозиторий и веса должен создать владелец; в текущей среде повторное GPU-обучение не проводилось.

Источники и конфигурации: README.md, docs/SOURCES.md, configs/experiment.json, artifacts/logs/runtime.json.